



I. Einführung und Motivation

Grobüberblick der Stochastik

Stochastik: Lehre von Zufallsprozessen

Wahrscheinlichkeitstheorie: Zufallsprozesse mit bekannten Wahrscheinlichkeiten

Beispiel: fairer Würfel

Statistik: Zufallsprozesse mit unbekannter Wahrscheinlichkeit

Beispiel: unfairer Würfel (Schätze die Wahrscheinlichkeit ab)

Randomisierte Algorithmen

Monte-Carlo-Algorithmen: geben immer eine Antwort, aber nicht jede Antwort ist richtig

Las-Vegas-Algorithmen: geben stets richtige Antworten, lassen jedoch ggf. auf sich warten

Freivalds-Algorithmus

Problemstellung: Zu drei gegebenen $n \times n$ Matrizen A, B, C entscheide, ob $A \cdot B = C$ ist.

Freivalds Algorithmus (1)

1. Wähle Zufallsvektor $x \in \{0, 1\}^n$.
2. Berechne $A \cdot (B \cdot x)$ und $C \cdot x$.
3. Ist $A \cdot (B \cdot x) \neq C \cdot x$, antworte mit $AB \neq C$.
4. Ist $A \cdot (B \cdot x) = C \cdot x$, antworte mit $AB = C$.

Antwort $AB \neq C$ unproblematisch, da $ABx \neq Cx$.

Antwort $AB = C$ problematisch, da von $ABx = Cx$ auf $ABy = Cy$ für alle Zufallsvektoren y geschlossen wurde.

Als Urnenmodell

Eine Urne $U_{A,B,C}$ enthält zu jedem Zufallsvektor $x \in \{0, 1\}^n$ eine gefärbte Kugel K_x :

- falls $ABx = Cx$, ist K_x blau,
- falls $ABx \neq Cx$, ist K_x rot.

Im Fall $AB = C$ sind alle Kugeln blau.

Freivalds Algorithmus (2)

1. Wähle eine positive ganze Zahl k .
2. Greife k -mal unabhängig in die Urne $U_{A,B,C}$.
3. Sind alle gezogenen Kugeln blau, so antworte mit $AB = C$.
4. Ist eine gezogene Kugel rot, so antworte mit $AB \neq C$.

Satz von Freivalds

Im Fall $AB \neq C$ ist höchstens die Hälfte aller Kugeln blau.

Färbungsproblem

F_j : Fachabteilung

A_i : Arbeitsgruppe

: Experte

: Expertin

	F_1	F_2	F_3	F_4	F_5	F_6	F_7
A_1	•		•	•		•	
A_2	•	•		•			•
A_3		•	•		•	•	
A_4	•			•	•		•
A_5	•	•	•			•	
A_6		•	•	•			•
A_7	•		•		•		•
A_8		•		•	•	•	

Frage: Gibt es eine Gesamtabordnung, so dass in den Arbeitsgruppen keine **reinen Herrenrunden** und keine **reinen Damenkränzchen** entstehen?

Zulässige Färbung:

	F_1	F_2	F_3	F_4	F_5	F_6	F_7
A_1	•		•	•		•	
A_2	•	•		•			•
A_3		•	•		•	•	
A_4	•			•	•		•
A_5	•	•	•			•	
A_6			•	•	•		•
A_7	•		•		•		•
A_8		•		•	•	•	

Abstrakt:

$F = [1 : 7]$ identifiziert die Fachabteilungen F_1, \dots, F_7 .

konkret: S_i beschreibt die Zusammensetzung der i -ten Arbeitsgruppe. Im Beispiel sind etwa $S_1 = \{1, 3, 4, 6\}$, $S_2 = \{1, 2, 4, 7\}$ usw.

Aufgabe: Färbe jedes Element von F jeweils mit einer von zwei Farben (rot, blau) so ein, dass keine der Teilmengen S_1, S_2, \dots, S_m einfarbig ist.

[Eine solche Färbung heiße (S_1, \dots, S_m) -zulässig.]

konkret: S_i einfarbig rot: reines Damenkränzchen,
 S_i einfarbig blau: reine Herrenrunde.

Las-Vegas-Färbungsalgorithmus

1. **Eingabe:** n -elementige Menge F sowie r -elementige, paarweise verschiedene Teilmengen S_1, \dots, S_m von F .
2. Färbe die Elemente von F gemäß Gleichverteilung blau oder rot.
3. Teste, ob Gesamtfärbung (S_1, \dots, S_m) -zulässig.
4. Falls zulässig, Färbung gefunden, sonst weiter mit 2.

Satz

Es sei $r \geq 2$ und $m \leq 2^{r-2}$. Dann gilt:

- (1) Es gibt eine (S_1, \dots, S_m) -zulässige Gesamtfärbung.
- (2) Im Mittel ist der Las-Vegas-Algorithmus spätestens nach zwei (!) Färbungsversuchen erfolgreich.

2. Wahrscheinlichkeitsräume

Wahrscheinlichkeitsraum

→ modelliert ein Zufallsexperiment (Ω, \mathcal{A}, P) .

Ω : Ergebnisraum

\mathcal{A} : Ereignis-Algebra

P : W-Maß

Eregebnisräume: Ausgang des Zufallsexperiments mengentheoretisch beschreiben

Einmaliges Würfeln: $\Omega = [1 : 6]$

n-maliges Würfeln:

1. Folge der gewürfelten Augenzahlen

$$\Omega_n = [1 : 6]^n = \{(\omega_1, \dots, \omega_n) \mid \forall i : \omega_i \in [1 : 6]\}$$

2 Häufigkeiten der gewürfelten Augenzahlen

$$\Omega'_n = \{(h_1, \dots, h_6) \in [0 : n]^6 \mid h_1 + \dots + h_6 = n\}.$$

Ω'_n ist dabei das Bild der Vergrößerungsabbildung

$$\Omega_n \ni \omega \mapsto (h_j := |\{i : \omega_i = j\}|)_{j \in [1:6]},$$

die jeder Augenzahlfolge das zugehörige **Histogramm** zuordnet.

Münzwurffolgen: $\Omega = \{0, 1\}^{\mathbb{N}} = \{\omega = (\omega_i)_{i \in \mathbb{N}} \mid \forall i : \omega_i \in \{0, 1\}\}$.

Satz 1.1. $\Omega = \{0, 1\}^{\mathbb{N}}$ ist überabzählbar unendlich.

Ereignisse: entsprechen Teilmengen A des Ergebnisraums

Ist $\omega \in \Omega$ das Ergebnis eines Zufallsexperiments, so sagt man im Fall

- ◆ $\omega \in A$: das Ereignis A ist **eingetreten**.
- ◆ $\omega \notin A$: das Ereignis A ist **nicht eingetreten**.

Beispiele: ■ Beim einmaligen Würfeln beschreibt die Teilmenge $A := \{2, 4, 6\}$ des Ergebnisraums $\Omega = [1 : 6]$ das Ereignis
Es wurde eine gerade Augenzahl gewürfelt.

■ Das Ereignis *Bei n Münzwürfen fällt mindestens k-mal Zahl* wird beschrieben durch die Teilmenge

$$A = \{\omega \in \{0, 1\}^n \mid \omega_1 + \dots + \omega_n \geq k\}$$

des Ergebnisraums $\Omega = \{0, 1\}^n$. [$0 \cong \text{Kopf}$, $1 \cong \text{Zahl}$.]

Ereignissysteme

System, was in konsistenter Weise alle Ereignisse fasst, sodass ihnen eine Wahrscheinlichkeit $P(A)$ zugewiesen werden kann

$$\mathcal{A} \subseteq 2^\Omega := \{X \mid X \subseteq \Omega\}$$

σ -Algebren als Ereignissysteme

System $\mathcal{A} \subseteq 2^\Omega$ heißt σ -Algebra über Ω , wenn gilt:

1. $\Omega \in \mathcal{A}$.
2. Gegenereignisse sind in \mathcal{A} : $A \in \mathcal{A} \Rightarrow A^c := \Omega \setminus A \in \mathcal{A}$.
3. Ist unter der Vereinigung abgeschlossen: $A_1, A_2, \dots \in \mathcal{A} \Rightarrow \bigcup_{i \geq 1} A_i \in \mathcal{A}$

(Ω, \mathcal{A}) bildet den Ereignisraum

Eigenschaften:

- (a) $\emptyset \in \mathcal{A}$.
- (b) $A, B \in \mathcal{A}$ impliziert $A \cup B \in \mathcal{A}, A \cap B \in \mathcal{A}, A \setminus B \in \mathcal{A}$.
- (c) \mathcal{A} ist unter abzählbar unendlicher Durchschnittsbildung abgeschlossen.

Beispiele:

Im Fall $\emptyset \neq A \subset \Omega$ gilt für die von $\mathcal{G} = \{A\}$ erzeugte σ -Algebra:

$$\sigma(\mathcal{G}) = \{\emptyset, A, A^c, \Omega\}.$$

Ist Ω höchstens abzählbar unendlich, so ist die von $\mathcal{G} := \{\{\omega\} \mid \omega \in \Omega\}$ erzeugte σ -Algebra die Potenzmenge von Ω :

$$\sigma(\mathcal{G}) = 2^\Omega.$$

Sei $\Omega = \mathbb{R}^n$ und $\mathcal{G} := \{\prod_{i=1}^n [a_i, b_i] : a_i, b_i \in \mathbb{Q} \wedge a_i < b_i\}$ das System aller achsenparallelen kompakten Quader in \mathbb{R}^n mit rationalen Endpunkten. Dann heißt

$$\mathcal{B}^n := \sigma(\mathcal{G})$$

die **Borelsche σ -Algebra** auf \mathbb{R}^n und jedes $A \in \mathcal{B}^n$ heißt eine **Borel-Menge**.

Typische σ -Algebren:

Diskreter Fall: Ω ist höchstens abzählbar unendlich. Hier setzt man $\mathcal{A} = 2^\Omega$.

Reeller Fall: $\emptyset \neq \Omega \subseteq \mathbb{R}^n$. Dann wählt man

$$\mathcal{A} = \mathcal{B}_\Omega^n := \{A \cap \Omega \mid A \in \mathcal{B}^n\}.$$

Übung: \mathcal{B}_Ω^n ist eine σ -Algebra.

System aller σ -Algebren über Ω

$$\Sigma(\Omega) := \{\mathcal{A} \mid \mathcal{A} \text{ ist } \sigma\text{-Algebra über } \Omega\}$$

Eigenschaften:

- (1) $\Sigma(\Omega)$ ist bezüglich Mengeninklusion halbgeordnet.
- (2) $\{\emptyset, \Omega\}$ ist die kleinste σ -Algebra über Ω .
- (3) 2^Ω ist die größte σ -Algebra über Ω .
- (4) Der Durchschnitt beliebig vieler σ -Algebren über Ω ist wieder eine σ -Algebra über Ω .
- (5) Zu jedem System \mathcal{G} von Teilmengen von Ω gibt es eine kleinste, \mathcal{G} enthaltende σ -Algebra über Ω . Diese von \mathcal{G} erzeugte σ -Algebra $\sigma(\mathcal{G})$ ist der Durchschnitt aller \mathcal{G} enthaltenden σ -Algebren über Ω :

$$\sigma(\mathcal{G}) = \bigcap_{\mathcal{G} \subseteq \mathcal{A} \in \Sigma(\Omega)} \mathcal{A}.$$

Wahrscheinlichkeitsmaße

$P(A) \in [0, 1]$ beschreibt die Wahrscheinlichkeit, dass Ereignis A eintritt

$P : \mathcal{A} \rightarrow [0, 1]$ ist ein W-Maß/W-Verteilung, wenn gilt:

1. Normierung: $P(\Omega) = 1$

2. σ -Additivität: $P\left(\bigsqcup_{i \geq 1} A_i\right) = \sum_{i \geq 1} P(A_i)$

Eigenschaften:

- (1) $P(\emptyset) = 0$.
- (2) $P(A \cup B) + P(A \cap B) = P(A) + P(B)$; insbesondere ist

$$P(A) + P(A^c) = 1.$$

(3) Monotonie: $A \subseteq B \Rightarrow P(A) \leq P(B)$.

(4) σ -Subadditivität: $P(\bigcup_{i \geq 1} A_i) \leq \sum_{i \geq 1} P(A_i)$.

(5) σ -Stetigkeit: Wenn $A_1 \subseteq A_2 \subseteq \dots$ und $A = \bigcup_{i \geq 1} A_i$ bzw. $A_1 \supseteq A_2 \supseteq \dots$ und $A = \bigcap_{i \geq 1} A_i$, so gilt

$$\lim_{n \rightarrow \infty} P(A_n) = P(A).$$

Wahrscheinlichkeitsfunktion/Zähldichte

$p(\omega)$ ordnet jedem Ergebnis $\omega \in \Omega$ eine Wahrscheinlichkeit zu

$$p : \Omega \rightarrow [0, 1] \text{ mit } \sum_{\omega \in \Omega} p(\omega) = 1$$

Konstruktion von W-Maßen

diskreter Fall:

Für P auf $(\Omega, \mathcal{P}^{\Omega})$ gilt:

$$1 \quad P(A) = \sum_{\omega \in A} P(\{\omega\})$$

$$2 \quad P(A) := \sum_{\omega \in A} p(\omega), \text{ mit } p : \Omega \rightarrow [0, 1] \text{ mit } \sum_{\omega \in \Omega} p(\omega) = 1$$

stetiger Fall:

Sei $\Omega \subseteq \mathbb{R}^n$ borelsch, und $\rho : \Omega \rightarrow [0, \infty)$ mit:

- (a) $\{x \in \Omega \mid \rho(x) \leq c\} \in \mathcal{B}_{\Omega}^n$ für alle $c > 0$
- (b) $\int_{\Omega} \rho(x) dx = 1$

Dann gilt für P auf $(\Omega, \mathcal{B}_{\Omega}^n)$:

$$P(A) = \int_A \rho(x) dx$$

Konvexität

Menge $K \subseteq \mathbb{R}^n$ ist konvex, wenn gilt:

$x, y \in K$ und $\lambda \in [0, 1]$ impliziert $\lambda y + (1 - \lambda)x \in K$.

konvexe Hülle: Sei $X \subseteq \mathbb{R}^n$, kleinste X enthaltende konvexe Hülle

$$\text{conv}(X) = \bigcap_{X \subseteq K, K \text{ konvex}} K$$

Konvexitätskombination: Beschreibung einer konvexen Hülle durch

$$\lambda_0 x_0 + \dots + \lambda_r x_r, \text{ mit } (\lambda_0, \dots, \lambda_r) \text{ eine Zähldichte}$$

Gleichverteilung

diskreter Fall:

W-Funktion:

$$\rho(\omega) := \frac{1}{|\Omega|}$$

Verteilung: $\mathcal{U}_{\Omega}(A) = |A|/|\Omega|$ (# günstigen Fälle / # möglichen Fälle)

stetiger Fall:

Sei $\Omega \subseteq \mathbb{R}^n$ Borel-Menge mit Volumen $0 < \lambda^n(\Omega) < \infty$

W-Funktion:

$$\rho(x) := \frac{1}{\lambda^n(\Omega)}$$

Verteilung: $\mathcal{U}_{\Omega}(A) = \lambda^n(A)/\lambda^n(\Omega)$

3. Zufallsvariable

Messbare Abbildung / Zufallsvariable

Seien (Ω, \mathcal{A}) und (Ω', \mathcal{A}') Messräume

Dann ist $X : \Omega \rightarrow \Omega'$ eine Zufallsvariable / (Ω, \mathcal{A}) -messbar, wenn die Urbilder im Ereignisraum liegen: $\forall A' \in \mathcal{A}' : X^{-1}[A'] := \{\omega \in \Omega \mid X(\omega) \in A'\} \in \mathcal{A}$.

$$X : (\Omega, \mathcal{A}) \rightarrow (\Omega', \mathcal{A}')$$

Für $\mathcal{A} = 2^\Omega$ ist jede Abbildung eine Zufallsvariable

Sparversion: Wird die σ -Algebra \mathcal{A}' von \mathcal{G}' erzeugt, $\sigma(\mathcal{G}') = \mathcal{A}'$, so ist $X : \Omega \rightarrow \Omega'$ bereits dann eine ZV, wenn gilt (Übung):

$$\forall A' \in \mathcal{G}' : X^{-1}[A'] \in \mathcal{A}.$$

Bildmaß

Sei $X : (\Omega, \mathcal{A}) \rightarrow (\Omega', \mathcal{A}')$

W-Maß P' zu P bzgl. X : $P'(A') := P(X^{-1}[A']) = P(\{X \in A'\}) =: P(X \in A')$ für $A' \in \mathcal{A}'$

Verteilungen

Bildmaß P bzgl. X ist Verteilung von X

Familie von W-Räumen: $((\Omega_i, \mathcal{A}_i, P_i))_{i \in I}$

Familie von ZVs. $X_i : (\Omega_i, \mathcal{A}_i) \rightarrow (\Omega, \mathcal{A})$

Die Familie $(X_i)_{i \in I}$ heißt **identisch verteilt**, wenn alle Verteilungen $P_i \circ X_i^{-1}$ übereinstimmen.

Beispiel. n -maliger Münzwurf mit fairer Münze.

- Hier ist $I = [1 : n]$, $(\Omega_i = \{0, 1\}^n, \mathcal{A}_i = 2^{\Omega_i}, P_i \equiv$ Gleichverteilung) für alle i . $(\Omega, \mathcal{A}) = (\{0, 1\}, 2^{\{0, 1\}})$.
- $X_i : \{0, 1\}^n \rightarrow \{0, 1\}$ sei die Projektion $(\omega_1, \dots, \omega_n) \mapsto \omega_i$.
- Dann sind X_1, \dots, X_n identisch verteilte ZVs, denn die Verteilung von jedem X_i ist die Gleichverteilung auf $\Omega = \{0, 1\}$.

Gemeinsame Verteilungen

Ereignisse, die von mehreren ZVs abhängen, können nicht durch die einzelnen Verteilungen beschrieben werden

Seien $X_i : (\Omega, \mathcal{A}) \rightarrow (\Omega_i, \mathcal{A}_i)$

Produktabbildung: $X := X_1 \otimes \dots \otimes X_n : \Omega \rightarrow \Omega_1 \times \dots \times \Omega_n$
 $X(\omega) := (X_1(\omega), \dots, X_n(\omega))$

→ ist ebenfalls eine Zufallsvariable

P_X : gemeinsame Verteilung der X_1, \dots, X_n

Produkt- σ -Algebra: $\mathcal{A}_1 \otimes \dots \otimes \mathcal{A}_n := \sigma\left(\bigcup_{j=1}^n \pi_j^{-1}[\mathcal{A}_j]\right) \subseteq 2^{\Omega_1 \times \dots \times \Omega_n}$

Beispiel:

Für P_X zugehörige Zähldichte p_X auf $[0 : n] \times [1 : n+1]$ gilt für $(k, h) \in [1 : n]^2$ gilt.

$$p_X(k, h) = \binom{n-h}{k-1} \cdot 2^{-n}$$

Es gilt: $p_X(0, h) = 0$, $p_X(k, n+1) = 0$, $p_X(0, n+1) = 2^{-n}$

Randverteilung

Marginalverteilung: gemeinsame Verteilung des Teilproduktes

$$X_{i_1} \otimes \dots \otimes X_{i_k} : \Omega \rightarrow \Omega_{i_1} \times \dots \times \Omega_{i_k}$$

Marginalisierung: Eliminieren der irrelevanten Komponenten durch komplettes Aufsummieren

$$p_{X_1 \otimes \dots \otimes X_k}(\omega_1, \dots, \omega_k) = \sum p_{X_1 \otimes \dots \otimes X_n}(\omega_1, \dots, \omega_k, \omega_{k+1}, \dots, \omega_n), \text{ mit } (i_1, \dots, i_k) = (1, \dots, k)$$

dabei wird – bei festem $(\omega_1, \dots, \omega_k)$ – über alle $(\omega_{k+1}, \dots, \omega_n) \in \Omega_{k+1} \times \dots \times \Omega_n$ summiert.

4. Standardmodelle

Laplace Räume:

W-Räume mit Gleichverteilung $(\Omega, 2^\Omega, \mathcal{U}_\Omega)$

Verteilung:

$$\mathcal{U}_\Omega(A) := \frac{|A|}{|\Omega|} = \frac{\text{Anzahl der günstigen Fälle}}{\text{Anzahl der möglichen Fälle}}.$$

W-Funktion:

$$\omega \mapsto \frac{1}{|\Omega|}.$$

Beispiele:

- n -maliger Wurf einer fairen Münze: $\Omega = \{0, 1\}^n$, $|\Omega| = 2^n$
- n -maliger Wurf eines fairen Würfels: $\Omega = [1 : 6]^n$, $|\Omega| = 6^n$
- Zahlenlotto: $\Omega = \{Z \mid Z \subset [1 : 49] \wedge |Z| = 6\}$, $|\Omega| = \binom{49}{6} = \frac{49!}{43! \cdot 6!}$
- Reihenfolge eines gut gemischten Skatblatts: $\Omega = \{\pi \mid \pi \text{ ist Permutation von } [1 : 32]\}$, $|\Omega| = 32!$

Kontinuierlicher Fall:

$$\mathcal{U}_\Omega(A) := \frac{\lambda^n(A)}{\lambda^n(\Omega)} = \frac{\text{günstiges Volumen}}{\text{mögliches Volumen}}.$$

Urnenmodell

Zufallsereignis: Mehrfaches Ziehen von teilweise verschiedenfarbigen Kugeln

Varianten:

Ω_{ZR} : Ziehen mit Zurücklegen unter Berücksichtigung der Reihenfolge

Ω_{zr} : Ziehen mit Zurücklegen ohne Berücksichtigung der Reihenfolge

Ω_{zR} : Ziehen ohne Zurücklegen unter Berücksichtigung der Reihenfolge

Ω_{Zr} : Ziehen ohne Zurücklegen ohne Berücksichtigung der Reihenfolge

Modellparameter:

N : Anzahl der Kugeln in der Urne

F : Menge der verschiedenen Farben der Kugeln in der Urne

N_f : Anzahl der f -farbigen Kugeln in der Urne ($f \in F$)

Beachte: $N = \sum_{f \in F} N_f$.

n : Anzahl der Ziehungen

Fiktiver Laplace Raum: Kugeln werden zusätzlich noch durchnummieriert

→ W-Raum behannt

Vergrößern um Information zu komprimieren

$$[1 : N]^n \xrightarrow{X_{ZR}} \Omega_{ZR} \xrightarrow{X_{Zr}} \Omega_{Zr}.$$

$$(2, 4, 5, 2, 1, 2, 3) \xrightarrow{X_{ZR}} (\bullet, \bullet, \bullet, \bullet, \bullet, \bullet, \bullet)$$

$$(\bullet, \bullet, \bullet, \bullet, \bullet, \bullet, \bullet) \xrightarrow{X_{Zr}} \begin{matrix} \bullet \\ \vdots \\ \bullet \\ \bullet \\ \bullet \end{matrix} \quad \begin{matrix} \bullet \\ \vdots \\ \bullet \\ \bullet \end{matrix}$$

Farbenhistogramme:

$$H = \begin{pmatrix} \bullet & \bullet & \bullet \\ 4 & 1 & 2 \end{pmatrix} \equiv \begin{array}{c} \bullet \\ \vdots \\ \bullet \\ \cdot \end{array} \quad \begin{array}{c} \bullet \\ \vdots \\ \cdot \end{array}$$

Raum: $\Omega_{Zr} = \{H \in [0:n]^F \mid \sum_{f \in F} H(f) = n\}$

ZV: $X_{Zr} : F^n \ni (f_1, \dots, f_n) \mapsto (F \ni f \mapsto |\{i \mid f_i = f\}|)$

Standardmodelle

Bernoulli-Verteilung:

$\Omega = \{0, 1\}^n$ 1: Erfolg, 0: Misserfolg

Erfolgswahrscheinlichkeit: p

Misserfolgwahrscheinlichkeit: $q = 1 - p$

Wahrscheinlichkeit: $p^k \cdot q^{n-k}$, mit $\omega = (\omega_1, \dots, \omega_n)$ und in ω genau k -mal eine Eins

Multinomialverteilung:

N -Kugeln mit Farbe $f \in F$

n -maliges Ziehen mit Zurücklegen

Wahrscheinlichkeit eines Farbenhistogramms:

$$P_{Zr}(H) = \binom{n}{H} \cdot \prod_{f \in F} \left(\frac{N_f}{N} \right)^{H(f)}$$

Multinomialkoeffizient: $\binom{n}{H} := \frac{n!}{\prod_{f \in F} H(f)!}$

→ Anzahl der Farbenfolgen der Länge n , in denen die Farben $1, \dots, c$ mit Vielfachheiten n_1, \dots, n_c vorkommen

Binomialverteilung

N -Kugeln mit zwei Farben $F = \{0, 1\}$, wobei 1 als Erfolg und 0 als Misserfolg

n -maliges Ziehen mit Zurücklegen

Wahrscheinlichkeit für k -Erfolge:

$$B_{n,p}(k) := \binom{n}{k} p^k (1-p)^{n-k}$$

Hypergeometrische Verteilung

N gefärbte Kugeln, wobei Farbe $f \in F$ mit Vielfachheit N_f dran kommt

n -Ziehungen ohne Zurücklegen

Wahrscheinlichkeit eines Farbenhistogramms:

$$P_Y(H) = \frac{\prod_{f \in F} \binom{N_f}{h_f}}{\binom{N}{n}}.$$

Geometrische Verteilung

Bernoulli-Experiment mit Erfolgswahrscheinlichkeit p

Wahrscheinlichkeit erstmals im k -ten Schritt Erfolg zu haben:

$$P(k) = p \cdot (1-p)^{k-1}$$

Poisson-Verteilung

Motivation: Wieviele E-Mails werden in einem festen Zeitintervall $(0, t]$, $t > 0$, über einen Mail-Server geleitet?

Ziehe von n Kugeln mit Zurücklegen mit 2 Farben:

Sorte 1: eine E-Mail ist im aktuellen Teilintervall weiterzuleiten;

Sorte 0: keine E-Mail ist im aktuellen Teilintervall weiterzuleiten.

Kugelanteil Sorte 1: $\alpha \cdot t/n$

Poisson-Verteilung zum Parameter λ

$$\lim_{n \rightarrow \infty} B_{n,p_n}(k) = e^{-\lambda} \frac{\lambda^k}{k!} =: P_\lambda(k)$$
 , mit $\lambda := \alpha \cdot t$ und $p_n := \lambda/n$

Gauß-Verteilung

Dichte-Funktion:

$$\phi_{m,v}(x) := \frac{1}{\sqrt{2\pi v}} e^{-(x-m)^2/(2v)}$$

m : Erwartungswert

v : Varianz

w -Maß: $N_{m,v}$

Standard-Normalverteilung: $N_{0,1}$

5. Bedingte Wahrscheinlichkeit und Unabhängigkeit

revidiertes W-Maß:

W-Maß P_A unter der Bedingung, dass A bereits eingetreten ist

- (a) $P_A(A) = 1$, denn A ist jetzt ein **sicheres Ereignis!**
 (b) Die Neubewertung der Teilereignisse B von A ist proportional zur ursprünglichen Bewertung:

$$\exists c_A > 0 \forall B \in \mathcal{A}, B \subseteq A : P_A(B) = c_A P(B).$$

Neubewertung:

(Ω, \mathcal{A}, P) ein W-Raum und $A \in \mathcal{A}$ mit $P(A) > 0$

$$P_A(B) := \frac{P(A \cap B)}{P(A)} \quad \text{für } B \in \mathcal{A}.$$

Anzahl der Fälle, in denen A **und** B eingetreten sind
Anzahl der Fälle, in denen A eingetreten ist

Bedingte Wahrscheinlichkeit

$$P(B|A) := \frac{P(A \cap B)}{P(A)} \quad \text{für } B \in \mathcal{A}$$

Satz. Durch $B \mapsto P(B|A)$ wird ein W-Maß P_A auf (Ω, \mathcal{A}) definiert.

Formel von Bayes

Satz. Es sei (Ω, \mathcal{A}, P) ein W-Raum und $\Omega = \sqcup_{i \in I} B_i$ eine disjunkte Zerlegung von Ω in höchstens abzählbar unendlich viele Ereignisse $B_i \in \mathcal{A}$ mit $P(B_i) > 0$. Dann gilt:

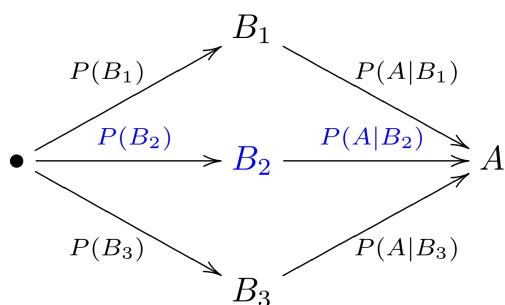
Fallunterscheidungsformel:

$$P(A) = \sum_{i \in I} P(B_i) P(A|B_i).$$

Formel von Bayes:

$$P(B_k|A) = \frac{P(B_k) P(A|B_k)}{\sum_{i \in I} P(B_i) P(A|B_i)}.$$

WegeModell



Wahrscheinlichkeit A über B_k zu erreichen:

$$P(B_k) \cdot P(A|B_k) = P(B_k) \cdot \frac{P(A \cap B_k)}{P(B_k)} = P(A \cap B_k).$$

Satz von Bayes: $P(B_k|A) = \frac{P(B_k) P(A|B_k)}{\sum_{i \in I} P(B_i) P(A|B_i)}.$ = \frac{\text{Wahrscheinlichkeit des Wegs über } B_k}{\text{Gesamtwahrscheinlichkeit aller Wege}}

Multiplikationsformel:

Sei $A_1, \dots, A_n \in \mathcal{A}$ und $A := A_1 \cap \dots \cap A_n$

$$P(A) = P(A_1) \cdot P(A_2 | A_1) \cdot P(A_3 | A_1 \cap A_2) \cdot \dots \cdot P(A_n | A_1 \cap \dots \cap A_{n-1}).$$

Konstruktion mehrstufiger Modelle

Ereignisräume: $\Omega_1, \dots, \Omega_n, n \geq 2$.

W-Funktionen: $p_1, \omega_i \in \Omega_i$ für $i < k$ sei $p_k |_{\omega_1, \dots, \omega_{k-1}}$

ZVs: $X_i : \Omega \rightarrow \Omega_i$ die i -te Projektion

Konstruktion des W-Maßes:

- (a) Für alle $\omega_1 \in \Omega_1$ gilt $P(X_1 = \omega_1) = p_1(\omega_1)$.
- (b) Für alle $k \in [2 : n]$ und $\omega_i \in \Omega_i$ gilt

$$P(X_k = \omega_k | X_1 = \omega_1, \dots, X_{k-1} = \omega_{k-1}) = p_k |_{\omega_1, \dots, \omega_{k-1}}(\omega_k),$$

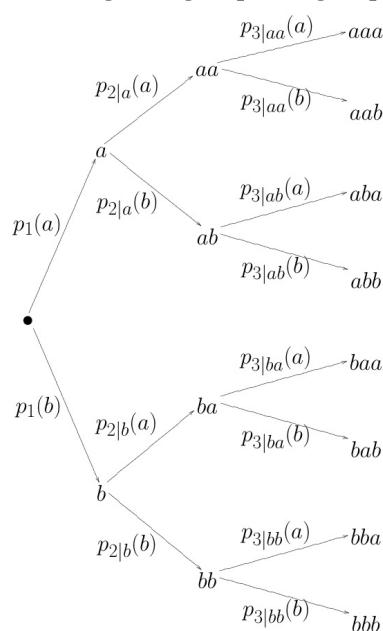
sofern $P(X_1 = \omega_1, \dots, X_{k-1} = \omega_{k-1}) > 0$.

Das W-Maß P ist gegeben durch

$$P(\{\omega\}) = p_1(\omega_1) \cdot p_2 |_{\omega_1}(\omega_2) \cdot p_3 |_{\omega_1, \omega_2}(\omega_3) \cdot \dots \cdot p_n |_{\omega_1, \dots, \omega_{n-1}}(\omega_n)$$

für $\omega = (\omega_1, \dots, \omega_n) \in \Omega$.

$$\Omega_1 = \Omega_2 = \Omega_3 = \{a, b\} \quad \Omega_1 \quad \Omega_1 \times \Omega_2 \quad \Omega_1 \times \Omega_2 \times \Omega_3$$



Stochastische Unabhängigkeit

Wahrscheinlichkeit, dass A eintritt, wird nicht durch das Eintreten von B beeinflusst

A, B ∈ A heißen **stochastisch unabhängig** bzgl. P

$$\Leftrightarrow P(A \cap B) = P(A)P(B).$$

Unabhängigkeit von Ereignisfamilien

Familie $(A_i)_{i \in I}$ heißen stochastisch unabhängig bzgl. P, wenn für alle $J \subseteq I \neq \emptyset$ gilt:

$$P\left(\bigcap_{j \in J} A_j\right) = \prod_{j \in J} P(A_j).$$

Unabhängigkeit von ZV-Familien

Familie $(Y_i)_{i \in I}$, mit $Y_i : (\Omega, \mathcal{A}) \rightarrow (\Omega_i, \mathcal{A}_i)$ heißen stochastisch unabhängig bzgl P, wenn für alle $J \subseteq I \neq \emptyset$ und alle $A_j \in \mathcal{A}_j$ mit $j \in J$ gilt:

$$P\left(\bigcap_{j \in J} \{Y_j \in A_j\}\right) = \prod_{j \in J} P(Y_j \in A_j).$$

Unabhängigkeitsskriterien

Satz. Es sei (Ω, \mathcal{A}, P) ein W-Raum und Y_1, \dots, Y_n eine endliche Familie von ZVs $Y_i : (\Omega, \mathcal{A}) \rightarrow (\Omega_i, \mathcal{A}_i)$. Dann gilt:

- (a) **Diskreter Fall:** Hat jedes Y_i einen endlichen Wertebereich Ω_i und ist $\mathcal{A}_i = 2^{\Omega_i}$, so ist $(Y_i)_{i \in [1:n]}$ genau dann unabhängig, wenn für beliebige $\omega_i \in \Omega_i$ gilt:

$$P(Y_1 = \omega_1, \dots, Y_n = \omega_n) = \prod_{i=1}^n P(Y_i = \omega_i).$$

- (b) **Reeller Fall:** Ist jedes Y_i reellwertig und ist $\mathcal{A}_i = \mathcal{B}_{\Omega_i}^1$, so ist $(Y_i)_{i \in [1:n]}$ genau dann unabhängig, wenn für beliebige $c_i \in \mathbb{R}$ gilt:

$$P(Y_1 \leq c_1, \dots, Y_n \leq c_n) = \prod_{i=1}^n P(Y_i \leq c_i).$$

6 Erwartungswert und Varianz

Kenngrößen reellwertiger Zufallsvariablen

Erwartungswert $E_P(x)$: P-gewichteter Mittelwert von X

Varianz $V_P(x)$: Abweichung von X von seinem Erwartungswert

Erwartungswert:

Allgemein: Definition. Die ZV $X : \Omega \rightarrow \mathbb{R}$ besitzt einen Erwartungswert, kurz: $X \in \mathcal{L}^1(P)$, wenn $X_{(n)} \in \mathcal{L}^1(P)$ für ein n (und damit für alle n) gilt. In dem Fall heißt

$$E_P(X) := \lim_{n \rightarrow \infty} E_P(X_{(n)})$$

$$E_P(X) = \int X dP.$$

diskreter Fall:

X besitzt Erwartungswert $\Leftrightarrow \sum_{x \in X[\Omega]} |x|P(X=x) < \infty$.

Erwartungswert: $E(X) = E_P(X) := \sum_{x \in X[\Omega]} xP(X=x)$, $E_P(X) = \sum_{\omega \in \Omega} X(\omega)P(\omega)$.

Menge aller ZVs mit Erwartungswert: $\mathcal{L}^1(P) := \{X : \Omega \rightarrow \mathbb{R} \mid E_P(|X|) < \infty\} = \mathcal{L}^1$

Stetiger Fall

Diskretisierung durch die ZV X durch Partitionierung der reellen Achse:

$$X_{(n)}(\omega) := \frac{k}{n}, \quad \text{wobei } k \in \mathbb{Z} \text{ und } \frac{k}{n} \leq X(\omega) < \frac{k+1}{n}.$$

Satz. Für die $1/n$ -Diskretisierungen $X_{(n)}$ von X gilt:

- (1) Für alle $n \in \mathbb{N}$ ist $X_{(n)} \leq X < X_{(n)} + \frac{1}{n}$.
- (2) Ist $X_{(m)} \in \mathcal{L}^1(P)$ für ein m , so ist $X_{(n)} \in \mathcal{L}^1(P)$ für alle n und in diesem Fall ist $(E_P(X_{(n)}))_{n \geq 1}$ eine Cauchy-Folge.

Rechenregeln:

1. Monotonie: Aus $X \leq Y$, d.h. $X(\omega) \leq Y(\omega)$ für alle $\omega \in \Omega$, folgt $E_P(X) \leq E_P(Y)$.

2. Linearität: $E_P(c_1 X_1 + c_2 X_2) = c_1 E_P(X_1) + c_2 E_P(X_2)$

3. \oplus -Additivität: Sind alle $X_n \geq 0$ und ist $X = \sum_{n \geq 1} X_n$, so gilt $E_P(X) = \sum_{n \geq 1} E_P(X_n)$.

4. Monotone Konvergenz: $E_P(Y) = \lim_{n \rightarrow \infty} E_P(Y_n)$.

5. Produktregel: X, Y sind unabhängig $E_P(X \cdot Y) = E_P(X)E_P(Y)$.

6. Cauchy-Schwarzsche Ungleichung: $E_P(XY)^2 \leq E_P(X^2) \cdot E_P(Y^2)$.

Bernoulli-Experiment

Sei X_1, \dots, X_n eine endliche Bernoulli-Folge zur Erfolgswahrscheinlichkeit p .

Dann beschreibt die ZV

$$S := \sum_{i=1}^n X_i$$

die Anzahl der Erfolge.

Erwartungswert:

$$\mathbf{E}_P(S) = \sum_{i=1}^n \mathbf{E}_P(X_i) = \sum_{i=1}^n P(X_i = 1) = np.$$

Erwartungswert bei W-Maßen mit Dichtefunktion

Es sei $\Omega \subset \mathbb{R}^d$ Borelsch und P das W-Maß auf $(\Omega, \mathcal{B}_\Omega^d)$ zur Dichtefunktion ρ , d.h. $P(A) = \int_A \rho(\omega) d\omega$ für alle $A \in \mathcal{B}_\Omega^d$.

$X \in \mathcal{L}'(P)$:

$$\mathbf{E}_P(X) = \int_{\Omega} X(\omega) \rho(\omega) d\omega.$$

Spezialfall: $\Omega = \mathbb{R}$, $X = \text{id}_{\mathbb{R}}$

$$\mathbf{E}_P(\text{id}_{\mathbb{R}}) = \int_{\mathbb{R}} x \rho(x) dx.$$

Momente von Zufallsvariablen

Gesamtheit aller ZVs, für die das r -te Moment existiert:

$$\mathcal{L}^r(P) := \{X : \Omega \rightarrow \mathbb{R} \mid X^r \in \mathcal{L}^1(P)\}.$$

1. Moment: Erwartungswert

2. Moment: Varianz

Es gilt: (1) Für $r \in \mathbb{N}$ ist $\mathcal{L}^r(P)$ ein reeller Untervektorraum von $\mathcal{L}^1(P)$.
(2) Die Räume $\mathcal{L}^r(P)$ bilden eine Kette:

$$\mathcal{L}^1(P) \supseteq \mathcal{L}^2(P) \supseteq \mathcal{L}^3(P) \supseteq \dots$$

Varianz und Kovarianz

Varianz: $\mathbf{V}(X) = \mathbf{V}_P(X) := \mathbf{E}_P([X - \mathbf{E}_P(X)]^2) = \mathbf{E}_P(X^2) - \mathbf{E}_P(X)^2$

Standardabweichung: $\sqrt{\mathbf{V}(X)}$

Kovarianz: $\text{Cov}_P(X, Y) := \mathbf{E}_P([X - \mathbf{E}_P(X)][Y - \mathbf{E}_P(Y)]) = \mathbf{E}_P(XY) - \mathbf{E}_P(X)\mathbf{E}_P(Y)$

Ist $\text{Cov}_P(X, Y) = 0$, so heißen X und Y unkorreliert.

Korrelationskoeffizient:

$$\rho(X, Y) := \frac{\text{Cov}(X, Y)}{\sqrt{\mathbf{V}(X)\mathbf{V}(Y)}}$$

Rechenregeln:

1. $\text{Cov}_P(aX + b, cY + d) = ac\text{Cov}_P(X, Y) \rightarrow \mathbf{V}_P(aX + b) = a^2\mathbf{V}_P(X).$

2. $\text{Cov}_P(X, Y)^2 \leq \mathbf{V}_P(X)\mathbf{V}_P(Y)$

$$3. \quad \mathbf{V}_P\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \mathbf{V}_P(X_i) + \sum_{j \neq i} \text{Cov}_P(X_i, X_j).$$

Sind X_1, \dots, X_n paarweise unkorreliert:

$$\mathbf{V}_P\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \mathbf{V}_P(X_i).$$

4. Sind X und Y unabhängig, so sind X und Y auch unkorreliert.

Spezialfall: Gleichverteilung

$$\mathbf{E}(X) = \bar{x} := \frac{1}{n} \sum_{i=1}^n x_i \quad \text{und} \quad \mathbf{V}(X) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2,$$

Spezialfall: Poisson-Verteilung

$$\mathbf{E}_P(X) = \lambda, \quad \mathbf{V}_P(X) = \lambda$$

Standardisierung:

Ist $X \in \mathcal{L}^2(P)$ mit $\mathbf{V}_P(X) > 0$, so folgt aus der Regel (1), dass die ZV

$$X^* := \frac{X - \mathbf{E}_P(X)}{\sqrt{\mathbf{V}_P(X)}}$$

standardisiert ist, d.h. es gilt $\mathbf{E}_P(X^*) = 0$ und $\mathbf{V}_P(X^*) = 1$.

Normalverteilung

$\mathcal{N}_{m,v}$ mit Dichtefunktion

$$\phi_{m,v}(x) := \frac{1}{\sqrt{2\pi v}} e^{-(x-m)^2/(2v)}$$

$$\text{Erwartungswert: } \mathbf{E}(\mathcal{N}_{m,v}) = \int_{\mathbb{R}} x \phi_{m,v}(x) dx = m$$

$$\text{Varianz: } \mathbf{V}(\mathcal{N}_{m,v}) = \int_{\mathbb{R}} (x - m)^2 \phi_{m,v}(x) dx = v.$$

7. Gesetze der großen Zahl

Stochastische Konvergenz

Motivation: $P\left(\frac{1}{2n} \sum_{i=1}^{2n} X_i = \frac{1}{2}\right) = \binom{2n}{n} 2^{-2n} \sim \frac{1}{\sqrt{\pi n}} \xrightarrow{n \rightarrow \infty} 0,$

→ Relative Häufigkeit liegt bei großem n nur zu einer sehr geringen Wahrscheinlichkeit beim Erwartungswert

$$P\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - \mathbf{E}_P(X_1)\right| < \epsilon\right) \xrightarrow{n \rightarrow \infty} 1,$$

→ liegt aber zu hoher Wahrscheinlichkeit nahe beim Erwartungswert

Folge $(Y_n)_n$ heißt **stochastisch konvergent** gegen Y ($Y_n \xrightarrow{P} Y$), wenn gilt:

$$\forall \varepsilon > 0: \lim_{n \rightarrow \infty} P(|Y_n - Y| < \epsilon) = 1$$

Schwaches Gesetz der großen Zahl

Seien $(X_i)_{i \geq 1}$ paarweise unkorrelierter ZVs in $\ell^2(\mathbb{P})$

Wahrscheinlichkeit, dass das arithmetische Mittel der ersten n zentralisierten ZVs mindestens um ε vom Mittel abweicht, ist beschränkt durch:

$$P\left(\left|\frac{1}{n} \sum_{i=1}^n (X_i - \mathbf{E}_P(X_i))\right| \geq \varepsilon\right) \leq \frac{v}{n\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0$$

Sind alle Erwartungswerte gleich:

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mathbf{E}_P(X_1)$$

Für Bernoulli-Versuche:

ZV $Y_n := (X_1 + \dots + X_n)/n$ die relative Häufigkeit der Erfolge

$$P(|Y_n - p| \geq \varepsilon) \leq \frac{\mathbf{V}_P(X_1)}{n\varepsilon^2} = \frac{p(1-p)}{n\varepsilon^2} \leq \frac{1}{4n\varepsilon^2}$$

Tschebyscheff-Ungleichung

Sei $X \in L^2(P)$

$$P(|X - E_P(X)| \geq \epsilon) \leq \frac{V_P(X)}{\epsilon^2}$$

Fast sichere Konvergenz

Seien Y_1, Y_2, Y_3 reelle ZVs

Folge $(Y_n)_{n \geq 1}$ konvergiert **P-fast sicher** gegen Y , wenn gilt:

Für alle Stellen $\omega \in \Omega$, an denen punktweise Konvergenz herrscht, gilt:

$$A := \{\omega \in \Omega : \lim_{n \rightarrow \infty} Y_n(\omega) = Y(\omega)\}$$

$$P(A) = 1$$

Fast sichere Konvergenz \Rightarrow stochastische Konvergenz

Sigma-stetigkeit von W-Maßen

Seien $(A_n)_{n \geq 1}$ eine aufsteigende Kette von Ereignissen, mit $A = \bigcup_{n \geq 1} A_n$

$$P(A) = \lim_{n \rightarrow \infty} P(A_n)$$

Starkes Gesetz der großen Zahl

Seien $(X_i)_{i \geq 1}$ ein Folge paarweise unkorrelierter ZVs in $L^2(P)$

$$\frac{1}{n} \sum_{i=1}^n (X_i - E_P(X_i)) \rightarrow 0 \quad P\text{-fast sicher.}$$

Borel-Cantelli Lemma

Seien $A_n \in \mathcal{A}$ und $A \equiv \limsup_{k \rightarrow \infty} A_k := \{\omega \in \Omega \mid \omega \in A_k \text{ für unendlich viele } k\}$

Dann gilt:

- (0) Ist $\sum_{k \geq 1} P(A_k) < \infty$, so ist $P(A) = 0$.
- (1) Ist $\sum_{k \geq 1} P(A_k) = \infty$ und sind die Mitglieder der Ereignisfamilie $(A_k)_{k \geq 1}$ paarweise stochastisch unabhängig, so gilt $P(A) = 1$.

Verteilungsfunktion der Gauß-Glocke

Verteilungsfunktion: $F_P := (\mathbb{R} \ni c \mapsto P((-\infty, c]) \in [0, 1]$

Dichtefunktion der Standardnormalverteilung $N_{0,1}$:

$$\phi(x) := \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$$

Verteilungsfunktion der Standardnormalverteilung:

$$\Phi(c) := N_{0,1}((-\infty, c]) = \int_{-\infty}^c \phi(x) dx.$$

Zentraler Grenzwertsatz

Supremumsabstand zweier Verteilungsfunktionen F und G :

$$d(F, G) := \sup_{c \in \mathbb{R}} |F(c) - G(c)|.$$

Seien $(X_i)_{i \geq 1}$ eine Folge unabhängiger, identisch verteilter reellwertiger ZVs in $L^2(P)$

$E_P(X_i) = m$, $V_P(X_i) = v > 0$, $S_n := X_1 + \dots + X_n$ die n -te Partialsumme

Standardisierung von S_n :

$$S_n^* = \frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{X_i - m}{\sqrt{v}}$$

Sei F_n die Verteilungsfunktion von S_n^*

Dann konvergiert diese im Supremumsabstand gegen die Verteilungsfunktion der Standardnormalverteilung

$$\lim_{n \rightarrow \infty} d(F_n, \Phi) = 0.$$

→ die Verteilungsfunktion der Standardisierung ($E_P=0$, $V_P=1$) ist die Standardnormalverteilung

8. Markov Ketten

Stochastische Matrizen

$\forall \neq \emptyset$ und $\tilde{\Pi} = (\tilde{\Pi}(x,y))_{x,y \in V}$ ist eine reellwertige Matrix

$\tilde{\Pi}$ heißt **Zeilenstochastisch**, wenn in jeder Zeile der Matrix eine W-Funktion steht:

1. alle Einträge liegen im Intervall $[0,1]$
2. Die Summe der Einträge jeder Zeile beträgt 1

Betrachtet werden Zufallsprozesse in V , die in jedem Schritt mit der Wahrscheinlichkeit $\tilde{\Pi}(x,y)$ von Zustand x in y wechselt.

$$x \xrightarrow{\tilde{\Pi}(x,y)} y.$$

Markov-Ketten

Seien X_0, X_1, \dots sind ZVs auf dem W-Raum (Ω, \mathcal{A}, P)

$X_i: (\Omega, \mathcal{A}) \rightarrow (V, 2^V)$ heißt Markov-Kette mit Zustandsraum V und Übergangsmatrix $\tilde{\Pi}$

Markov-Eigenschaft muss gelten:

$$P(X_0 = x_0, \dots, X_n = x_n) > 0 \quad P(X_{n+1} = x_{n+1} | X_0 = x_0, \dots, X_n = x_n) = P(X_{n+1} = x_{n+1} | X_n = x_n),$$

→ darf nur vom aktuellen Zustand abhängen (Gegenwart)

→ stationäre Übergangswahrscheinlichkeit bleibt gleich

Startverteilung: $\alpha := P \circ X_0^{-1}$

Mehrstufige Modelle

Konstruktion mehrstufiger Modelle umfasst Markov-Ketten als Spezialfall

Setze die Wahrscheinlichkeiten. $p_{k|\omega_0, \dots, \omega_{k-1}}(\omega_k) := \Pi(\omega_{k-1}, \omega_k),$

Dann existiert zu jeder Startverteilung α auf V genau ein W-Maß P^α auf:

$$(\Omega, \mathcal{A}) := \left(\prod_{k \geq 0} V, \bigotimes_{k \geq 0} 2^V \right)$$

Sodass $X_n: \Omega \rightarrow V$ eine Markov-Kette zu $\tilde{\Pi}$ und α bildet:

$$X_n: (\omega_k)_{k \geq 0} \mapsto \omega_n,$$

Ist $\alpha = \delta_x$ für ein $x \in V$ (sicherer Start in x), so schreibt man kurz P^x statt P^α .

Matrixpotenzen

Die n -te Potenz: Π^n enthält an der Position (x, y) die Wahrscheinlichkeit genau in n Schritten von Zustand x in y zu wechseln

$$P^x(X_n = y) = \Pi^n(x, y).$$

Übergangsgraphen

Visualisierung der Markov-Kette zu Π durch einen gerichteten, kantengewichteten Übergangsgraphen $(V, E, \tilde{\Pi})$

V : endliche Knotenmenge

E : Kantenmenge $E := \{(x, y) \in V \times V \mid \Pi(x, y) > 0\}$

$\tilde{\Pi}$: Kantengewichte

Websurfen als Markov-Prozess

gerichteter Graph:

$G = (V, E)$ V : Menge der Webseiten
 E : Menge der Links

Menge der von x erreichbaren Webseiten:

$$G[x] := \{y \in V \mid (x, y) \in E\} \cup \{x\}$$

Modellierung:

$p \in (0, 1)$: gleichverteilte Wahrscheinlichkeit Surfer gibt eine neue URL ein

$1-p$: Wahrscheinlichkeit Surfer folgt einem Link von x oder bleibt auf Seite x

Übergangswahrscheinlichkeit:

$$\Pi(x, y) := \begin{cases} \frac{p}{N} & \text{falls } (x, y) \notin E \\ \frac{p}{N} + \frac{1-p}{|G[x]|} & \text{falls } (x, y) \in E. \end{cases}$$

Es gilt: $\sum_{y \in V} \Pi(x, y) = \underbrace{\sum_{y=1}^N \frac{p}{N}}_{=p} + \underbrace{\sum_{y \in G[x]} \frac{1-p}{|G[x]|}}_{=1-p} = 1.$

Ergodensatz

Bedingung: Es existiert ein $L \geq 1$, sodass alle Einträge Π^L positiv sind

Dann existiert die Grenzverteilung: W-Funktion $\rho = (\rho_1, \dots, \rho_N)$

Eigenschaften:

1. $\lim_{m \rightarrow \infty} \Pi^m =: \Pi^\infty$: $\Pi^\infty = \begin{pmatrix} \rho_1 & \rho_2 & \dots & \rho_N \\ \rho_1 & \rho_2 & \dots & \rho_N \\ \vdots & \vdots & \dots & \vdots \\ \rho_1 & \rho_2 & \dots & \rho_N \end{pmatrix}$

2. $(\Pi^m)_{m \geq 1}$ konvergiert exponentiell schnell gegen Π^∞

3 Für die Grenzverteilung gilt: $\rho \Pi = \rho$.

9. Stuhrkurs Statistik

Statistische Modelle

$$M = (\mathcal{X}, \mathcal{A}, (P_\theta)_{\theta \in \Theta})$$

\mathcal{X} : Stichprobenraum

\mathcal{A} : σ -Algebra auf \mathcal{X}

$(P_\theta)_{\theta \in \Theta}$: Familie von W-Maßen $(\mathcal{X}, \mathcal{A})$, $|\Theta| \geq 2$

Bemerkung: \mathcal{X} statt Ω , da ZV $X: \Omega \rightarrow \mathcal{X}$ die detaillierte Beschreibung Ω auf \mathcal{X} , die tatsächliche beobachtbaren Ergebnisse, abbildet

Modellklassen

Sei $M = (\mathcal{X}, \mathcal{A}, (P_\theta)_{\theta \in \Theta})$

parametrisches Modell: $\Theta \subset \mathbb{R}^d$ für $d \in \mathbb{N}$

einparametrisches Modell: $d = 1$

diskretes Modell: \mathcal{X} ist diskret ($|\mathcal{X}| \leq |\mathbb{N}|$, $\mathcal{A} = 2^\mathcal{X}$)

Jedes P_θ ist gegeben durch: W-Funktion $p_\theta: x \mapsto p_\theta(x) := P_\theta(\{x\})$

stetiges Modell: \mathcal{X} ist eine Borel-Teilmenge eines \mathbb{R}^n

$\mathcal{A} = 2^\mathcal{X}$ Borel- σ -Algebra

P_θ besitzt eine Dichtefunktion p_θ

Standardmodell: M ist diskret oder stetig

Produktmodelle

Sei $(E, \mathcal{E}, (Q_\theta)_{\theta \in \Theta})$ ein statistisches Modell

n-faches Produktmodell: $(\mathcal{X}, \mathcal{A}, (P_\theta)_{\theta \in \Theta}) := (E^n, \mathcal{E}^{\otimes n}, (Q_\theta^{\otimes n})_{\theta \in \Theta})$

$X_i: \mathcal{X} \rightarrow E$ beschreibt den Ausgang des i-ten Teilexperiments

$\rightarrow X_i$ sind bzgl. $P_\theta = Q_\theta$ unabhängig und identisch verteilt

Zufallszahlen: Erwartungswert und Varianz

Seien $\Omega = [0, \Theta]^n$, P_θ Gleichverteilung auf Ω

Dichtefunktion: $p_\theta(\omega) := \theta^{-n} (\omega \in \Omega) = \left(\frac{1}{\Theta}\right)^n$

$X := \text{id}_\Omega$: modelliert das Gesamtprotokoll der n Stichproben

X_i : Ergebnis der i-ten Stichprobe

Dann gilt: $E_\theta(X_i) = \theta/2$ und $V_\theta(X_i) = \theta^2/12$.

Statistiken und Schätzer

Sei $(\mathcal{X}, \mathcal{A}, (P_\theta)_{\theta \in \Theta})$ ein statistisches Modell und (Σ, \mathcal{S}) ein Messraum.

Statistik: ZV $S : (\mathcal{X}, \mathcal{A}) \rightarrow (\Sigma, \mathcal{S})$

Schätzer: $\tau : \Theta \rightarrow \Sigma$ ordnet jedem $\theta \in \Theta$ eine Kenngröße $\tau(\theta) \in \Sigma$ zu
Statistik $T : \mathcal{X} \rightarrow \Sigma$ ist Schätzer für τ

→ für $\tau = \text{id}_\Theta$ ist T ein Schätzer für Θ

erwartungstreu: Erwartungswert des Schätzers ist gleich dem zu schätzenden Parameters

verzerrt: Erwartungswert weicht vom tatsächlichen Wert ab, liegt aber in der Nähe (fast erwartungstreu)

Maximum-Likelihood-Schätzer

Idee: $p_{T(x)}(x) = \max_{\theta \in \Theta} p_\theta(x)$.

→ Bestimme den Schätzwert $T(x)$ so, dass der Parameter für $p_{T(x)}(x)$ die maximale Aufttrittswahrscheinlichkeit für x erzeugt

Likelihood-Funktion: $p : \mathcal{X} \times \Theta \rightarrow [0, \infty)$ $p(x, \theta) := p_\theta(x)$

Likelihood-Funktion zum Beobachtungswert x : $p(x, \cdot) : \Theta \rightarrow [0, \infty)$

Maximum-Likelihood-Schätzer (MLE)

$T : \mathcal{X} \rightarrow \Theta$ für θ

Für jedes $x \in \mathcal{X}$ muss $T(x)$ eine Maximalstelle von $p(x, \cdot)$ sein:

$$p(x, T(x)) = \max_{\theta \in \Theta} p(x, \theta).$$

Log-Likelihood-Funktion: $\log p(x, \cdot)$

- besitzt die selben Maximalstellen, wie die Likelihood-Funktion
- oft leichter zu berechnen

Schätzung der Erfolgswahrscheinlichkeit

Reißzwecke fällt mit unbekannter Wahrscheinlichkeit θ auf die Spitze

Statistisches Modell: Binomialmodell $([0:n], 2^{[0:n]}, (B_{n,\theta})_{\theta \in [0,1]})$

Likelihood-Funktion: $p(k, \theta) = \binom{n}{k} \theta^k (1-\theta)^{n-k}$.

MLE-Bestimmung: Betrachtung der Nullstellen der Ableitung der log-Likelihood-Funktion. $0 = \frac{d}{d\theta} \log p(k, \theta)$

$$0 = \frac{d}{d\theta} (k \log \theta + (n-k) \log(1-\theta)) = \frac{k}{\theta} - \frac{n-k}{1-\theta}.$$

\Rightarrow Nullstelle: $\theta = k/n$. \rightarrow Maximum

$\Rightarrow T(k) := k/n$ einziger MLE für θ .

Schätzung des Zufallszahlensbereichs

- In einer Fernsehshow führt der Moderator einen Apparat vor, der Zufallszahlen im Intervall $[0, \theta]$ gemäß Gleichverteilung ausspuckt, wenn er vom Moderator auf den Wert $\theta > 0$ eingestellt wurde.
- Zwei Spieler dürfen den Apparat $n = 10$ mal bedienen und sollen dann θ möglichst gut schätzen.
- Wer besser rät, hat gewonnen.

Statistisches Modell: Produktmodell der skalierten Gleichverteilung

$([0, \infty)^n, \mathcal{B}_{[0, \infty]}^{\otimes n}, (\mathcal{U}_{[0, \theta]}^{\otimes n})_{\theta > 0})$

Likelihood-Funktion: $p((x_1, \dots, x_n), \theta) = \begin{cases} \theta^{-n} & \text{falls } x_1, \dots, x_n \leq \theta, \\ 0 & \text{sonst.} \end{cases}$

MLE-Bestimmung:

Bei festem $x = (x_1, \dots, x_n)$ ist $p(x, \theta)$ genau für $\theta = \max(x_1, \dots, x_n)$ maximal, denn $(0, \infty) \ni \theta \mapsto \theta^{-n}$ ist streng monoton fallend. Wegen $x_1, \dots, x_n \leq \theta$ muss $\theta \geq \max(x_1, \dots, x_n)$ sein. Also ist

$$\tilde{T}_n(x) = \max(x_1, \dots, x_n)$$

der MLE.

MLE im Gauß'schen Produktmodell

Bei vielen Experimenten kann angenommen werden, dass die Messwerte durch eine normalverteilte Zufallsvariable mit Erwartungswert m und Varianz $v > 0$ modelliert werden können. In unabhängige Experimente

Statistisches Modell: n -fache Gauß'sche Produktmodell

$(\mathcal{X}, \mathcal{A}, (P_\theta)_{\theta \in \Theta}) := (\mathbb{R}^n, \mathcal{B}^n, (\mathcal{N}_{m,v}^{\otimes n})_{m \in \mathbb{R}, v > 0})$

Likelihood-Funktion: $p((x_1, \dots, x_n), \theta) = \prod_{i=1}^n N(m, v)(x_i) = (2\pi v)^{-n/2} \exp \left[-\sum_{i=1}^n \frac{(x_i - m)^2}{2v} \right]$

MLE-Bestimmung:

Likelihood-Funktion wird maximal, wenn m so gewählt wird, dass die quadratische Abweichung minimal wird

Erwartungswert: $m = M((x_1, \dots, x_n)) := \frac{1}{n} \sum_{i=1}^n x_i$

Varianz: $v = V((x_1, \dots, x_n)) := \frac{1}{n} \sum_{i=1}^n (x_i - M)^2$

Korrigierte Stichprobenvarianz

Sei $n \geq 2$ und $(\mathbb{R}^n, \mathcal{B}^n, \mathcal{Q}_\theta^{\otimes n} : \theta \in \Theta)$ ein reelles n -faches Produktmodell.

Stichprobenmittelwert: $M = \frac{1}{n} \sum_{i=1}^n X_i$

Korrigierte Stichprobenvarianz: $V^* = \frac{1}{n-1} \sum_{i=1}^n (X_i - M)^2$

$\Rightarrow m=M, v=V$ sind erwartungstreue Schätzer

